


모델 보고서

Two-Tower Recommend System



Two-tower 모델은 두 개의 독립적인 타워에서 생성된 임베딩 간의 유사도를 기반으로 작동한다. 이 모델은 타 추천 시스템 모델에 비해 확장성과 범용성이 뛰어나고, 특히 본 조가 직면한 Cold-start problem을 효과적으로 해결할 수 있어 선정되었다. 본 조의 추천 시스템에서는 장소의 리뷰 수와 좋아요 수, 장소의 유형 (음식점, 카페, 관광 명소), 장소의 위치 등의 데이터를 텍스트화하여 임베딩함으로써 성공적으로 Cold-start problem을 해결할 수 있었다. 본 조의 추천 시스템은 유저와 장소 데이터를 각각 임베딩 모델에 통과시켜 벡터화한 뒤, 두 임베딩 간의 내적을 통해 유사도를 산출하는 방식으로 구성된다. 최종적으로 유사도가 가장 높은 상위 10개 장소를 추천 결과로 도출하였다.

임베딩 모델 선정

현재 본 조에 쓰이는 추천 시스템은 타워에서 생성된 임베딩들간의 유사도를 기반으로 한다. 이에 5개의 다른 임베딩 모델들을 실험하여 임베딩 성능과 샘플 데이터를 이용한 코사인 유사도 맵 분석을 이용하여 나온 결과들로 최종 임베딩 모델을 선정하였다.

모델 소개

실험 대상으로 bert 계열 모델 2개 (klue/bert-base, klue/roberta-base), bge-m3 계열 모델 2개 (baai/bge-m3, dragonkue/bge-m3-ko) 그리고 multilingual-e5 계열 모델 (dragonkue/multilingual-e5-small-ko)를 선정하였다.

모델별 임베딩 벡터 분석 비교


모델의 임베딩 성능을 파악하기 위해 클러스터링이 쉬운 restaurant 카테고리 데이터를 이용하였다. 데이터를 각각 모델로 임베딩 후 클러스터링이 잘 되었는지 시각화하였고, 임베딩 대상 데이터를 100개 샘플링하여 각각의 유사도를 2차원 행렬로 만들어 모델이 데이터 간 유사도를 어떻게 파악하고 있는지에 대해 시각화하였다.

실험 결과

(bge-m3)

다국어 임베딩 모델



1024차원의 output 크기



(dragonkue/bge-m3-ko)

bge-m3 기반 한국어 사전학습 모델



1024차원의 output 크기



(klue/bert-base)

한국어 기반 bert 모델



768차원의 output 크기



(klue/roberta-base)

한국어로 사전학습된 roBERTa 모델


768차원의 output 크기



(dragonkue/multilingual-e5-small-ko)

intfloat/multilingual-e5-small-ko의 한국어 사전학습 모델

경량화되어 384차원의 output 크기



그래프 지표 설명 (각주)

pca/t-SNE 그래프 : 고차원 (384, 768, 1024) 벡터를 저차원으로 축소 후 데이터를 군집화

그래프 점 색깔 : K-means 알고리즘으로 나눈 6개의 그룹 의미

PCA 누적 분산 설명 비율 : 데이터를 설명하는 데 얼마나 많은 주성분 개수가 요구되는가에 대한 비율

실험 결과 분석과 결과

bert 계열의 한국어 사전학습 계열인 roberta/bert 모델은 다른 모델과는 달리 대부분의 유사도가 높게 산출된다. 이는 각 데이터를 충분히 구분하지 못하고 대부분의 데이터를 유사하게 판단하는 현상을 의미한다. 반면 bge-m3 계열 모델은 대부분의 유사도를 낮게 산출한다. 이는 각 데이터를 충분히 구분하고 있는 중이지만 추천에 필요한 잠재적 유사성을 표현하지 못한다는 것을 의미한다. 속도와 자원 사용량 측면에서는 bge-m3 계열 모델은 1024차원으로 임베딩을 하기 때문에 타 모델보다 임베딩 시에 시간이 오래 소모된다. 따라서 본 조는 적절한 유사도 분포를 형성하여 변별력을 확보

함과 동시에, 타 모델보다 경량화되어 서비스 서빙에 유리한 dragonkue/multilingual-e5-small-ko를 최종 모델로 선정하였다.

임베딩 테스트

실험 개요

본 조의 실시간 추천 서비스의 응답 속도 최적화와 서버 운영 비용 절감을 목표로, 주요 임베딩 모델 간의 효율성을 비교 분석하였다. 이를 위해 동일한 하드웨어 환경에서 장소 데이터를 임베딩하는 과정을 수행하여, 각각의 소요 시간, 메모리 사용량, 메모리 부하, CPU 점유율을 정량적으로 측정해 비교하였다.

비교 결과는 다음과 같다.

실험 결과

모델명 (Model ID)	소요 시간 (Latency)	메모리 사용량 (Total)	메모리 부하 (증가량)	CPU 점유율	비고
dragonkue/multilingual-e5-small-ko	24.29 sec (24,289 ms)	1,026.70 MB	+584.64 MB	52.0%	✅ 최적 (Selected)
klue/bert-base	63.30 sec (63,302 ms)	1,317.61 MB	+875.41 MB	56.9%	Baseline 1
klue/roberta-base	63.40 sec (63,399 ms)	1,291.73 MB	+849.40 MB	57.9%	Baseline 2
dragonkue/bge-m3-ko	228.02 sec (228,023 ms)	2,583.97 MB	+2,140.90 MB	59.1%	고성능/고비용
baai/bge-m3	242.59 sec (242,587 ms)	2,581.45 MB	+2,138.38 MB	58.7%	고성능/고비용

실험 결과 분석

서비스 운영 과정에서 실시간으로 유저 데이터를 받아 임베딩해 추천을 하는 서비스 특성상 시간과 자원의 양이 다른 상황에 우선적으로 고려될 사항이다. 실험 결과 타 모델에 비해 dragonkue/multilingual-e5-small-ko가 소요 시간, 메모리 사용량, 메모리 부하에서 월등한 모습을 보였다.

모델별 자체 실험 결과 비교

모델 실험

임베딩 모델이 실제 본 조의 추천 시스템에 얼마나 맞는지를 알아보기 위해 자체 실험을 진행하였다. 실험 과정은 다음과 같다. 우선 llm을 사용해 페르소나와 그 페르소나의 태그-실제 예상 장소 데이터 쌍을 만들었다. 그 후 각각의 임베딩 모델들을 사용해 페르소나 유저와 장소 임베딩을 진행 후 recall@10값과 ndcg@10값을 산출하였다.

실험 결과

Model	Dimensions	Category	Recall@10	NDCG@10
bge-m3	1024	Restaurant	0.2061	0.1741
(Multilingual)		Cafe	0.2245	0.1965
		Tourspot	0.1487	0.1260
klue/roberta-base	768	Restaurant	0.2082	0.1683
(Korean)		Cafe	0.2507	0.2238
		Tourspot	0.2247	0.1970
klue/bert-base	768	Restaurant	0.1934	0.1481

(Korean)		Cafe	0.2502	0.2208
		Tourspot	0.2060	0.1817
multilingual-e5-small-ko	384	Restaurant	0.2088	0.1779
(Selected)		Cafe	0.2211	0.1966
		Tourspot	0.1665	0.1453

실험 결과 분석

위 실험에서는 차원이 클수록 추천 성능이 좋게 나올 것이라는 사전 예상과 달리 임베딩 크기가 작아도 더 좋은 성능을 낼 수 있다는 것을 확인하였다. 데이터 특성상 대부분 한국어로 이루어진 텍스트를 사용하는데, 그 과정에서 다국어 모델인 bge-m3 계열 모델보다 한국어로 사전학습된 klue/bert 계열 모델이 유의미하게 성능 차이를 내고 있음을 확인할 수 있었다. 최종 모델로 선정한 multilingual-e5-small-ko의 경우 klue/roberta-base 대비 수치적인 성능은 낮으나 bge-m3 계열 모델보다는 좋은 성능을 보였다. 무엇보다도 임베딩 차원이 384차원으로 타 모델 대비 절반 이하라는 점에 주목하였다. 이는 실제 서빙 시 벡터 연산 속도와 메모리 효율성을 획기적으로 개선할 수 있음을 의미한다.

따라서 본 조는 절대적인 성능 수치보다는 서비스의 응답 속도와 자원 효율성을 최우선 가치로 판단해, 성능과 경량화의 균형이 가장 뛰어난 dragonkue/multilingual-e5-small-ko를 최종 선정하였다.

Reranking

도입 배경

앞서 설명한 Two-Tower Recommendation system은 임베딩 벡터 간의 코사인 유사도 기반으로 빠르게 후보군을 추려내는 데에 좋은 성능을 보이고 있다. 그러나 벡터 유사도만으로는 장소 데이터 특유의 복잡한 성격이나 구체적인 추천 상황을 100퍼센트 반영하기 어렵다는 한계가 존재한다. 이에 본 조는 1차로 선별된 후보 장소들을 LLM에 입력하여, 유저의 성향과 장소의 세부 정보를 논리적으로 비교 분석한 후 재정렬하는 단계를 추가하였다.

리랭킹 시스템 구조 및 로직

Two-tower 모델이 상위 20개의 후보 장소를 추출하면, LLM이 이 후보군과 유저의 특성 텍스트를 입력받아 다음과 같은 추론 과정을 거쳐 리랭킹과 최종 후보 10개를 선정한다.

1. 인풋 구성 : 회원가입 단계와 추천 전 단계에서 얻은 유저의 특성과 후보 장소들의 메타데이터를 프롬프트로 구성한다.
2. 추론 : LLM이 각 장소가 유저의 특성에 얼마나 부합하는지를 논리적으로 추론한다. 이 과정에서 인풋에서 받은 20개의 후보 장소의 순서가 재정렬된다.
3. 아웃풋 도출 : 가장 유사도가 높은 순서대로 최종 Top 10을 선정한다.

실제 리랭킹 예시

카테고리	장소명	순위 변동	증감	점수
tourspot	시그니엘 서울 리트릿 시그니엘 스파	9위 → 1위	▲ 8	0.6333
tourspot	신라면세점 서울점	13위 → 2위	▲ 11	0.6253
tourspot	신세계백화점 본점	14위 → 3위	▲ 11	0.6211
tourspot	서울광장	2위 → 4위	▼ 2	0.6488
tourspot	여의도공원	3위 → 5위	▼ 2	0.6480
tourspot	청계천	6위 → 6위	—	0.6378
tourspot	서서울호수공원	7위 → 7위	—	0.6363
tourspot	서울색공원	5위 → 8위	▼ 3	0.6402
tourspot	명동	4위 → 9위	▼ 5	0.6444
tourspot	한강	1위 → 10위	▼ 9	0.6678

위 예시는 실내 장소와 고급스러운 분위기를 선호하는 유저의 케이스이다. 기존 모델에서는 대중적인 인지도가 높은 “한강”, “명동”이 상위권에 배치되었다. 그러나 리랭킹 과정에서 “명동”, “한강” 등의 저명도가 높은 장소보다 “시그니엘 서울 리트릿 시그니엘 스파”, “신라면세점 서울점”, “신세계백화점 본점” 등의 사용자 취향이 반영된 장소가 더 높은 순위를 얻을 수 있게 되었다.

기대 효과

이 과정을 통해 단순 임베딩 벡터 내적 과정에서 놓칠 수 있는 유저의 디테일한 취향을 잡아낼 수 있게 되었으며, 데이터의 한계로 인해 임베딩 과정에서 발생하는 오류들을 정정할 수 있다.